

如何在模型里使用定性变量

变量的数学运算合理吗？

小胖

目录

ONE 定量与定性

数学运算的合理性

TWO 虚拟变量

最常用的定性变量处理方法

THREE 从定性变量到定量变量


保留定性变量的信息

定量与定性

特征工程

对数据建模通常分为特征提取、搭建模型、模型评估三个步骤

- 特征提取是最为关键的一步
- 对已有变量的转换和使用是特征提取最常见的手段




定量与定性

特征工程的原则

不管模型的具体形式如何，本质上都是对特征的数学运算：


- 提供给模型的特征能进行数学运算，也就是特征是数字化的
- 特征的数学运算是合理的



定量与定性


特征的分类

- 将数据转换为数字通常是比较容易的
- 按特征的性质，可以分为两类：
 - 数值型特征，也称定量特征
 - 类别型特征，也称定性特征
- 重点是保证特征的数学运算是合理的



定量与定性

特征的分类



目录


ONE 定量与定性
数学运算的合理性

TWO 虚拟变量
最常用的类别特征处理方法

THREE 从定性变量到定量变量
保留定性变量的信息

虚拟变量

一个简单的例子



- 当性别 = 男时, $x_1 = 1$, 否则等于 0; x_2 类似

男 x_1

女 x_2

$$y = ax_1 + bx_2 + cz + d + \varepsilon$$

- x_1 、 x_2 被称为虚拟变量 (dummy variable)

$$x_1 + x_2 = 1$$


$$y = (b - a)x_2 + cz + (a + d) + \varepsilon$$

引发多重共线性问题

虚拟变量

1到n-1

- 将有n种可能取值的类别型特征转换成n-1个虚拟变量
- 遇到高维的类别性特征时，建模变量会急剧上升，给建模带来困难
- 每个虚拟变量能给模型带来的“信息量”很小



目录

ONE 定量与定性
数学运算的合理性

TWO 虚拟变量
最常用的定性变量处理方法

THREE 从类别特征到数值特征
保留类别特征的信息

从类别特征到数值特征

保留类别特征的信息

使用虚拟变量转换类别特征时，往往会损失掉类别特征的部分信息

- 特别是对于有序类别特征

在实践中，针对特定的场景和特征，有更加“精细”的特征转换方法来保留类别特征的信息

- 比如针对有序类别特征（二分类问题）的Ridit scoring

Ridit scoring

假设类别变量 x 有 t 个可能的取值

$1, 2, \dots, t$

各个类别在整体中所占比例为

$p_1, p_2, \dots, p_t$


其他变量相同时， x 从1到 t ， $y=1$ 的概率依次减少

定义Ridit scoring：

$$B_i = \sum_{j < i} p_j - \sum_{k > i} p_k$$

从类别特征到数值特征

保留类别特征的信息



THANK YOU

—