

多变量的烦恼

多重共线性

小胖

目录

ONE 多重共线性效应

多重共线性对模型的影响

TWO 应对方案



检测方法与解决方法

THREE 虚拟变量陷阱


由虚拟变量引起的多重共线性

多重共线性效应

何时多重共线性



多重共线性
讨论的问题



多重共线性效应


一个简单的例子

模型关系：

$$y = 0.7x_1 - 1.1x_2 + 0.3x_3 + \varepsilon$$

- x_1 与 x_3 强相关：相关系数0.958
- x_1 与 x_2 不相关； x_2 与 x_3 弱相关

数据概况



多重共线性效应

对模型的影响


加入新的不相关变量，
不影响原有变量的“表现”

- 1

$y = a_1x_1 + b + \varepsilon$
- 2

$y = a_2x_2 + b + \varepsilon$
- 3

$y = a_1x_1 + a_2x_2 + b + \varepsilon$



	模型	a_1 估计值	a_1 标准差	a_1 是否显著 (5%)	a_2 估计值	a_2 标准差	a_2 是否显著 (5%)
1	只有 x_1	0.972	0.279	是	—	—	—
2	只有 x_2	—	—	—	-1.113	0.244	是
3	x_1 和 x_2	0.972	0.021	是	-1.113	0.021	是

$$y = 0.7x_1 - 1.1x_2 + 0.3x_3 + \varepsilon$$

多重共线性效应

对模型的影响


加入新的相关变量，
严重危害原有变量的“表现”

- 1

$y = a_1x_1 + b + \varepsilon$
- 2

$y = a_3x_3 + b + \varepsilon$
- 3

$y = a_1x_1 + a_3x_3 + b + \varepsilon$




	模型	a_1 估计值	a_1 标准差	a_1 是否显著 (5%)	a_3 估计值	a_3 标准差	a_3 是否显著 (5%)
1	只有 x_1	0.972	0.279	是	—	—	—
2	只有 x_3	—	—	—	1.090	0.282	是
3	x_1 和 x_3	-0.168	0.959	否	1.260	1.017	否

$$y = 0.7x_1 - 1.1x_2 + 0.3x_3 + \varepsilon$$


多重共线性效应

原因

无多重共线性 $\Rightarrow y = x + z$



多重共线性 $\Rightarrow$ $y_I = x_I + z_I$
 $y_I = 3x_I$
 $y_I = 2x_I + 0.5z_I$



目录

ONE 多重共线性效应

多重共线性对模型的影响

TWO 应对方案


检测方法与解决方法

THREE 虚拟变量陷阱

由虚拟变量引起的多重共线性

应对方案

检测方法




应对方案

解决方法

按引起原因，多重共线性可以分为两类


- 数据型：由数据自身分布引起的共线性
- 结构型：由特征转换引起的共线性，比如 x 和 x^2




应对方案

增加数据量

- 多重共线性对模型的“危害”在于增大了模型参数估计值的方差
- 增加数据量能有效地解决这个问题



大数据的价值




应对方案


变量归一化

- 将变量归一化可以有效解决结构化共线性
- 变量归一化还有利于模型的训练

变量 x_3 和 x_3^2



将 x_3 的中心置零



目录

ONE 多重共线性效应

多重共线性对模型的影响

TWO 应对方案

检测方法与解决方法


THREE 虚拟变量陷阱

由虚拟变量引起的多重共线性

虚拟变量陷阱

虚拟变量回顾

虚拟变量




如果转换为n个虚拟变量：
 $x_1, \dots, x_n$ ；则

$$x_1 + x_2 + \dots + x_n = 1$$

虚拟变量陷阱

虚拟变量陷阱

虚拟变量陷阱



THANK YOU

—