

模型陷阱

过度拟合与模型幻觉

小胖

目录

ONE 模型陷阱概述

过度拟合、模型幻觉

TWO 机器学习的解决方法

惩罚项、网格搜寻

THREE 统计分析的解决方法


假设检验

模型陷阱概述

模型的双重用途

在现实生活中，搭建模型主要有两种用途

- 正向应用：对未知情况做预测
- 反向应用：解释数据之间的联动效应



模型陷阱概述

过度拟合





过度拟合

- 对于已知数据，模型越复杂“效果越好”
- 模型的扩展性非常差

解决方法可以分为两类

- 数据层面
- 模型层面


模型越复杂，效果越好？




模型陷阱概述

数据层面的解决方法





现实情况



将数据一分为二




正确的模型效果估算



模型陷阱概述

模型层面的解决方法：奥卡姆剃刀原则



Occam's Razor: 如无必要, 切勿假定繁多



模型陷阱概述


模型幻觉

在现实中，控制模型复杂程度的方法主要有两种：

- 模型本身的复杂度
- 模型使用的特征，包括个数以及特征的复杂度

而第二种方法很容易引起所谓的“模型幻觉”问题

- 不相关的特征被加入模型里，且被认为与预测结果有相关性



目录

ONE 模型陷阱概述

过度拟合、模型幻觉

TWO 机器学习的解决方法

惩罚项、网格搜寻

THREE 统计分析的解决方法

假设检验

机器学习的解决方法

一个例子

生产记事本

日期	玩偶个数	成本	第几天
04/01	10	7.7	1
04/02	10	9.87	2
04/03	11	10.87	3
04/04	12	12.18	4
04/05	13	11.43	5
04/06	14	13.36	6
04/07	15	15.15	7
04/08	16	16.73	8
04/09	17	17.4	9
...	...	...	...

x y

$$y = x + \varepsilon$$

比如 z 表示是否是晴天


加入不相关的变量 z

$$y = ax + bz + c$$

真实值 = 0

机器学习的解决方法


惩罚项



机器学习的解决方法

网格搜寻


Lasso回归, 模型参数随alpha的变化情况



如何得到最优的Alpha???

机器学习的解决方法

网格搜寻



$\alpha=1$, 因为对应的技术指标最好

机器学习的解决方法


参数与超参数

a, b, c 是模型参数,
能使用算法得到最优解


$$L = \frac{1}{2n} \sum_i (y_i - ax_i - bz_i - c)^2 + \alpha(|a| + |b| + |c|)$$

α 是模型超参数,
没有最优解算法

模型无超参数：



模型有超参数：



目录

ONE 模型陷阱概述

过度拟合、模型幻觉

TWO 机器学习的解决方法

惩罚项、网格搜寻

THREE 统计分析的解决方法

假设检验

统计分析的解决方法

假设检验

OLS Regression Results

Dep. Variable:	y	R-squared:	0.963				
Model:	OLS	Adj. R-squared:	0.959				
Method:	Least Squares	F-statistic:	222.8				
Date:	Tue, 25 Apr 2017	Prob (F-statistic):	6.38e-13				
Time:	21:39:40	Log-Likelihood:	-31.141				
No. Observations:	20	AIC:	68.28				
Df Residuals:	17	BIC:	71.27				
Df Model:	2						
Covariance Type:	nonrobust						
=====							
	coef	std err	t	P> t	[0.025	0.975]	
const	-0.8983	0.953	-0.942	0.359	-2.910	1.113	
x	1.0400	0.050	20.722	0.000	0.934	1.146	
z	-0.3619	0.571	-0.634	0.535	-1.566	0.843	
=====							
Omnibus:	1	b和c的估计值	1.295	Durbin-Watson:	2	但b和c都	2.209
Prob(Omnibus):		都不等于0	0.523	Jarque-Bera (JB):		不显著	0.852
Skew:			-0.061	Prob(JB):			0.653
Kurtosis:			1.996	Cond. No.			66.7
=====							

$y = ax + \cancel{bz} + c$

3 将变量z排除出模型，重新建模

1 b和c的估计值都不等于0

2 但b和c都不显著

统计分析的解决方法

两种方法比较

应对模型幻觉的方法

机器学习：加入惩罚项

- 更加自动化、工程化、不需要太多的人工干预
- 理论基础较差，模型的可解释性变差

统计分析：假设检验

- 理论基础更加牢靠、可以更好地理解数据之间的关系
- 需要较多的人工干预，随意性较大

THANK YOU

—