

# 如何解决二元分类问题

逻辑回归模型

小胖



# 目录

## ONE 线性模型为何失效

模型假设

## TWO 从线性到非线性

窗口效应、sigmoid函数


## THREE 逻辑回归的模型细节

似然函数、损失函数、预测结果


# 线性模型为何失效

一个简单的例子

在生活中，我们经常会遇到二元选择问题



在数学上，如果用 $y$ 表示选择的结果，那么 $y$ 只有两个可能的取值：0或者1



# 线性模型为何失效

线性回归的模型结果

如果使用线性回归模型解决二元分类问题：


$$y_i = ax_i + b + \varepsilon_i$$

其中


$$\varepsilon_i \sim N(0, \sigma^2)$$

这是模型假设

用线性回归拟合数据



模型误差



这与模型假设相矛盾



# 线性模型为何失效

线性回归的阿喀琉斯之踵

严谨的数学运算

模型预测公式


模型参数估计

模型理论推导

模型假设

唯一的软肋

有本事，别射我脚跟啊！！！！



# 目录

## ONE 线性模型为何失效

模型假设

## TWO 从线性到非线性

窗口效应、sigmoid函数

## THREE 逻辑回归的模型细节

似然函数、损失函数、预测结果




# 从线性到非线性

购物与窗口效应

从经济学的角度来讲，购物能给消费者带来两种相反的效应：

- 正效应：满足客户的需求等
- 负效应：花费金钱等

如果正效应大于负效应，则消费者会购买，否则就不购买



# 从线性到非线性

probit回归

latent variable model  
(隐含变量模型)

$$y_i^* = X_i\varphi + \theta_i$$

$$y_i^{\sim} = X_i\omega + \tau_i$$


$$y_i = \begin{cases} 1, & y_i^* > y_i^{\sim} \\ 0, & y_i^* \leq y_i^{\sim} \end{cases}$$

Probit回归模型  
的推导过程

虽然名字里面有“回归”二字，  
但它并不解决回归问题

$$z_i = y_i^* - y_i^{\sim} = X_i\gamma + \varepsilon_i$$

$$\gamma = \varphi - \omega$$



$$P(y_i = 1) = 1 - P(\varepsilon_i \leq -X_i\gamma)$$

$$P(y_i = 1) = P(z_i > 0) = P(\varepsilon_i > -X_i\gamma)$$



# 从线性到非线性

逻辑分布与sigmoid函数

逻辑分布

$$f(x) = \frac{e^{-x}}{(1 + e^{-x})^2}$$

sigmoid函数


$$S(x) = \frac{1}{1 + e^{-x}}$$

逻辑回归公式

$$P(y_i = 1) = \frac{1}{1 + e^{-X_i\beta}}$$

$$\ln \frac{P(y_i = 1)}{1 - P(y_i = 1)} = X_i\beta$$

用逻辑分布近似正态分布



# 目录

## ONE 线性模型为何失效

模型假设

## TWO 从线性到非线性

窗口效应、sigmoid函数

## THREE 逻辑回归的模型细节

似然函数、损失函数、预测结果




# 逻辑回归的模型细节

## 指示函数与类别表示

在分类模型的理论讨论中，我们常常使用指示函数，其中A表示一个给定的集合

$$1_A(x) = \begin{cases} 1 & \text{若 } x \in A \\ 0 & \text{若 } x \notin A \end{cases}$$



对于分类问题，在具体的计算过程中，我们常常用一个n维向量来表示数据的类别（也就是变量y）

对于2元分类问题：

$$(1_{y=0}, 1_{y=1}) \begin{cases} \xrightarrow{y=0} (1,0) \\ \xrightarrow{y=1} (0,1) \end{cases}$$

对于3元分类问题：

$$(1_{y=0}, 1_{y=1}, 1_{y=2})$$

# 逻辑回归的模型细节

统计学角度：似然函数

逻辑回归的直接建模  
对象是 $y=1$ 的概率

$$P(y_i = 1) = \frac{1}{1 + e^{-X_i\beta}}$$

定义逻辑回归的似然函数 $L$

$$H(X_i) = \frac{1}{1 + e^{-X_i\beta}}$$
$$L = \prod_i H(X_i)^{1_{(y_i=1)}} [1 - H(X_i)]^{1_{(y_i=0)}}$$

结合变量的真实值，可以得到数据出现的概率

$$P(y_i) = P(y_i = 1)^{1_{(y_i=1)}} \times P(y_i = 0)^{1_{(y_i=0)}}$$

根据最大似然估计法，得到模型参数的估计值

$$\hat{\beta} = \operatorname{argmax}_{\beta} L = \operatorname{argmax}_{\beta} \ln L$$

$$\hat{\beta} = \operatorname{argmax}_{\beta} \sum_i 1_{(y_i=1)} \ln H(X_i) + 1_{(y_i=0)} \ln [1 - H(X_i)]$$

# 逻辑回归的模型细节

机器学习角度：损失函数

$y$ 是随机变量，根据真实值， $y$ 的概率分布是

| $P(y = 0)$ | $P(y = 1)$ |
|------------|------------|
| $1_{y=0}$  | $1_{y=1}$  |

两个概率分布之间的差距，就是模型的损失

数学上，可以使用交叉熵来衡量两个概率分布之间的差距

$p(x)$ 与 $q(x)$ 之间的交叉熵为

$$-\sum_x p(x) \ln q(x)$$

交叉熵的理论基础是KL散度

根据逻辑回归模型， $y$ 的概率分布是

| $P(y = 0)$                            | $P(y = 1)$                |
|---------------------------------------|---------------------------|
| $e^{-X_i\beta} / (1 + e^{-X_i\beta})$ | $1 / (1 + e^{-X_i\beta})$ |

逻辑回归的损失函数LL定义如下：


$$H(X_i) = \frac{1}{1 + e^{-X_i\beta}}$$

$$LL = -\sum_i 1_{(y_i=1)} \ln H(X_i) + 1_{(y_i=0)} \ln[1 - H(X_i)]$$



# 逻辑回归的模型细节

机器学习角度：损失函数



# 逻辑回归的模型细节

## 最终预测结果

逻辑回归模型的直接结果是y=1的概率

为了得到最终类别的预测，需要做进一步的转换

- 人为选定一个阈值Alpha
- 当预测的y=1的概率大于这个阈值时，最终的预测结果就等于1

$$\hat{y}_i = \begin{cases} 1, & \frac{1}{1+e^{-X_i\beta}} > \alpha \\ 0, & \text{else} \end{cases}$$

通常Alpha等于0.5

**THANK YOU**

—